

Diseño de un sistema basado en algoritmos genéticos para la planificación de rutas de un robot móvil en un ambiente proporcionado por un ingeniero industrial

Facultad de Ingeniería, UNAM

Francisco Javier Durán López, Daniela Ivonne Enriquez Díaz

16 de Junio del 2020

Resumen. Durante toda su vida, el hombre moderno ha buscado la manera de obtener mayores ganancias, la cual es una de las principales tareas de los ingenieros industriales. Para eso la planificación de rutas es un método que les ha entregado resultados significativos, a pesar de la existencia de varias soluciones útiles para esta tarea, hoy en día las industrias cambian año con año debido al avance exponencial de la tecnología, por eso es necesario el desarrollo de nuevos métodos y una de las tecnologías más utilizadas para esto es la inteligencia artificial, que gracias a su gran adaptación y desarrollo, sus métodos de aprendizaje son cada vez más especializados en el estudio de problemas de optimización y entre esos métodos se encuentran los algoritmos genéticos.

En el presente artículo se propone un sistema basado en un algoritmo genético para la planificación de rutas. La principal característica del algoritmo es que es un algoritmo genético simple con variación en los operadores genéticos. Permite a los Ingenieros Industriales poder definir el punto de partido y llegada del robot móvil, además de la cantidad de obstáculos y el número de casillas del terreno o mapa. Con diferentes escenarios, se prueba que el algoritmo es capaz de obtener rutas, además se muestra que con cambios en los parámetros del algoritmo la eficiencia y robustez aumentan. El funcionamiento del Algoritmo Genético puede ser comprobado gracias a la interfaz gráfica desarrollada.

Abstract- Throughout his life, the mo-

modern man has sought ways to make higher profits, which is one of the main tasks of industrial engineers. For this, the route planning is a method that has delivered significant results, despite the existence of several useful solutions for this task, nowadays the industries change year by year due to the exponential advancement of technology, that is why it is necessary to develop new methods and one of the most used technologies for this is the artificial intelligence, which thanks to its great adaptation and development, its learning methods are increasingly specialized in the study of optimization problems and among these methods are genetic algorithms.

This article proposes a system based on a genetic algorithm for route planning. The main feature of the algorithm is that it's a simple genetic algorithm with variation in its genetic operators. It allows industrial engineers to define the departure and arrival point of the mobile robot, in addition to the number of obstacles and the number of squares on the terrain or map. With different scenarios, it is proved that the algorithm is capable of obtaining routes, and it is also shown that with changes in the algorithm parameters the efficiency and robustness increase. The operation of the Genetic Algorithm can be verified thanks to the developed graphical interface.

Palabras claves: Algoritmo Genéticos, Robots Móviles, Logística, Planificación de ruta

Keywords: Genetic algorithms, Mobile Robots, Logistics, Route Planning

1. Introducción

En la gestión de almacenaje y diseño de rutas, es indispensable un diseño que optimice el espacio y que los costos sean los mínimos posibles [19]. Los ingenieros industriales son los encargados de este estudio. Aunque el uso de métodos convencionales ayudan al análisis matemático; muchos de estos no suelen dar una respuesta factible, por prefieren implementar nuevas tecnologías computacionales, como lo es la Inteligencia Artificial[19], [21].

Dentro de los algoritmos importantes de la Inteligencia Artificial (IA) y la computación se encuentran los Algoritmos Genéticos (AG), que aunque se sabe que existen conceptos que pueden ser similares (programación evolutiva, programación genética, estrategias de evolución) existe una evidente diferencia entre cada uno de estos siendo los algoritmos genéticos el que mejor representación y optimización de resultados otorga.

Los algoritmos genéticos han tomado mucha popularidad dentro de la industria, ya que es una técnica que se basa de la modelación matemática, que a diferencia de métodos tradicionales de distribución, los AG buscan nuevas referencias esperando tener un mejor comportamiento. Esto permite que los ingenieros industriales diseñen rutas que ayuden a reducir tiempos y subir las ganancias de las empresas. Sin embargo, al ser un ambiente que siempre se encuentra en movimiento, es decir las áreas de trabajo están en constante renovación debido a que los materiales requieren mantenimiento o simplemente el acomodo de las máquinas no ha sido la óptima; es imposible que un robot se aprenda una sola

ruta de trabajo [2],[4].

Por ello se enfocará en los algoritmos genéticos; ya que éstos se basan en la naturaleza y siempre busca una adaptación a su entorno otorgando la solución óptima [4]. Aunque aún se siga necesitando de una intervención humana, se cree que en el futuro evolucionará a tal escala que será el método más utilizado para el autoaprendizaje, lo cual es el gran objetivo de la Inteligencia Artificial.

Teniendo en cuenta lo anterior, se enfocará en lograr identificar una ruta más corta para robot móvil utilizando un algoritmo genético en un ambiente conocido y así diseñar nuestro programa.

1.1. Algoritmos genéticos

Es una herramienta de optimización de búsqueda que se basa del principio de evolución de Darwin, el cual habla sobre el proceso de evolución y adaptación[2],[3],[4]. Para esto, los algoritmos genéticos se basan en un modelo matemático donde se toma todo un conjunto de soluciones y le aplica una prueba donde se juzga que tan bueno es el desempeño y la clasifica como buena o mala respuesta. El proceso se repite hasta obtener la solución óptima posible[16],[17]. Para tener una respuesta mejor, es necesario establecer una cierta cantidad de poblaciones; ya que esto permite un mayor campo de exploración de búsqueda dando como resultado una respuesta global.

Al basarse en la selección natural, es necesario que se lleve con cierto orden para llevar a cabo su implementación[3]: Selección de la representación genética, el cual se dividen

principalmente en estos tipos:

1. Selección de población.
2. Selección de la representación genética, el cual se dividen principalmente en tres tipos:
 - a) **Selección:** es igual a la supervivencia de la mejor estrategia y se basa por la función objetivo[3],[4].
 - b) **Crossover o Cruza:** mezcla entre individuos[3],[4].
 - c) **Mutación:** el cual hace modificaciones aleatorias[3],[4].
3. Definición de los operadores genéticos[3].

1.2. Aplicaciones

Los algoritmos genéticos, al ser bastante flexibles en su funcionamiento son capaces de adaptarse a cualquier área de trabajo en la que se requiera una optimización de resultados[3]. Esto se debe a que los modelos de distribución tradicionales trabajan con cierta cantidad de datos que otorgan una respuesta parcial o incompleta, mientras que los AG otorgan respuestas más dinámicas y completas[17].

Otras áreas en la que es mayormente utilizado es en el Diseño Asistido por Computadora (CAD), logística empresarial, control de robots, pronósticos, redes neuronales, en la química y hasta en el arte [4],[16].

Es por ello que se considera a los algoritmos genéticos tan importantes, ya que este ofrece grandes beneficios; ya que a diferencia de otros métodos de la IA, en esta no es

necesario alterar toda la estructura del programa aun si existe algún tipo de cambio o alteración en las entradas.

2. Antecedentes

Los Algoritmos Genéticos (AG) pueden abarcar casi cualquier campo que se desee. Esto se debe gracias a la flexibilidad con la que pueden adaptarse a la mayoría de los problemas en los que hay alguna optimización, algunas de sus aplicaciones más estudiadas en trabajos científicos son en campos como la logística[4], [7-10], [12], teoría de control [6] o robótica [1-3],[11].

En cierta intersección de la logística y la robótica se encuentra el campo de la planificación de rutas, encargado del estudio de la optimización de rutas en ciertos ambientes. Para poder obtener un claro ejemplo de cómo los AG pueden ser relacionados y aplicados a la determinación de rutas, basta con ver el trabajo que muchos autores han estudiado en problemas de distribución [4], [7-10], [12], determinando rutas y medios de transporte con costos mínimos para atender demandas en distintos puntos, lo cual lo hace un problema conveniente para resolver con AG. Los AG utilizados son diferentes en sus codificaciones u operadores genéticos, sin embargo, en todos se ha logrado mejorar considerablemente los costos, de esta manera es evidente las ventajas de la obtención de mejores rutas en ciertos ambientes.

Es evidente que en ambientes reales, el número de variables que intervienen a la hora de planificar eficientemente una ruta es casi

imposible de cuantificar o controlar, lo cual lleva a los expertos a una simplificación del objeto de estudio tomando ciertas consideraciones para facilitar su trabajo, a pesar de esto, los resultados obtenidos hasta ahora no difieren mucho a la hora de probarlos en ambientes reales. Existen varios enfoques para su estudio[1-3],[11], uno de los más estudiados debido a sus aplicaciones y acotaciones es la planeación de rutas estáticas para Robots Móviles (RM), que se encarga de encontrar rutas que van de un punto de inicio a un punto final en un terreno o mapa conocido, en el cual pueden existir obstáculos que el RM debe de evadir[1].

En estudios previos varios AG han sido desarrollados para resolver el problema de encontrar la ruta efectiva de un RM que se mueve de una posición inicial a una posición objetivo en un ambiente estático o dinámico con obstáculos. Algunos de ellos han mejorado aspectos como la codificación de los individuos en el AG (codificación de matriz) y nuevos operadores de mutación [1],[11], se ha logrado calcular rutas óptimas no sólo en un espacio estático sino que también en un ambiente dinámico, siendo capaz de volver a calcular rutas al momento de que el ambiente cambie, comparado con algoritmos muy utilizados en la IA como A* o G*, se han obtenido mejores resultados en términos de tiempos y complejidad computacional [1]. Con este tipo de algoritmos diseñados, se puede verificar que es viable modificar los AG convencionales para obtener resultados convenientes a problemas específicos.

Los estudios anteriores han sentado las bases para poder hacer viable el presente traba-

jo, que busca obtener un sistema inteligente basado en un AG para la planificación de rutas de un RM en un ambiente con obstáculos; dadas las ventajas de los resultados buscados, se añade la posibilidad al usuario de modelar mapas a su conveniencia.

3. Método

El algoritmo genético utilizado en este caso es muy parecido al Algoritmo Genético Simple (AGS) o clásico [5], con algunas variaciones en sus operadores genéticos. La representación del cromosoma y función de evaluación son basados en el trabajo de Jianping Tu and Simon X. Yangt [11].

3.1. AG propuesto

3.1.1. Representación de cromosoma

En un espacio de $n \times n$ casillas, un gen es representado por 4 bits, los primeros tres indican la dirección que el RM tendrá el paso siguiente, el último indica si avanzará a una casilla diferente o no. Hay a lo máximo $n \times n$ pasos (El caso en que el robot pasa por todas las casillas), se recomienda usar $4n$ como longitud del cromosoma o número de genes (ver Fig. 1 y 2).

3.1.2. Inicialización de la población

Se inicializa un conjunto de cromosomas de manera aleatoria, el número de cromosomas o tamaño de población más utilizado por investigadores va desde 25 a 100 cromosomas.




Figura 1: Tu, J.,; Yang, S. X. (2003, September). A chromosome encoding. [Figura] [11]




Figura 2: Tu, J.,; Yang, S. X. (2003, September). Direction encoding. [Figura] [11]

3.1.3. Selección

Se utiliza el método tradicional de la ruleta [13]

3.1.4. Función de evaluación

Si la casilla tiene un obstáculo se le da un valor de 300, si está libre tiene valor de 0 y si es el objetivo tiene un valor de -0.9.

$$f = \sum_{j=1}^K d_j(1 + w_j) + 100r$$

Donde:

w_j : Es el valor de la casilla j .

d_j : Es la distancia entre dos genes adyacentes.

Su valor es 1 si es una casilla horizontal o verticalmente adyacente, es $\sqrt{2}$ si es diagonalmente adyacente.

K : Es el total de casillas que se mueve el robot.

r : Es la distancia euclidiana desde la última casilla de cada individuo al punto final.

3.1.5. Cruza

Se utiliza el método de cruza por un punto [13].

3.1.6. Mutación

Ocasionalmente (probabilidad de mutación baja) un gen cambia su valor de manera aleatoria, para mantener la diversidad de la población.

3.2. Interfaz de usuario

Se desarrolla una interfaz de $n \times n$ casillas, donde el usuario configura: las casillas que tendrán obstáculos a su conveniencia, el punto de inicio y punto final del RM.

4. Resultados

Se realizaron distintos experimentos de simulación con la interfaz de usuario creada con la interfaz de Python: Tkinter utilizando el algoritmo genético desarrollado descrito previamente. En las figuras [3-10] de lado izquierdo primero se configura el escenario seleccionando las casillas donde se quieren los obstáculos, una vez que ya se configuró, se calcula la ruta y finalmente cuando el algoritmo acaba de ejecutarse, del lado derecho se muestra la ruta obtenida. Se muestra de color amarillo el punto de inicio designado en el código, de color rojo el punto al que se tiene que llegar designado también en el código y de color verde es la ruta obtenida una vez que los individuos o soluciones evolucionaron el número total de generaciones indicadas.

El espacio de simulación es una cuadrícula en 2-D, se presentan los resultados de una cuadrícula de 10×10 casillas. Se han considerado los siguientes escenarios con parámetros diferentes del AG (Ver Cuadro 1), para cada uno se obtuvo el costo del mejor individuo durante cada generación para poder observar la convergencia del costo, donde un menor costo significa que se llegó más cerca del punto final:

Escenario	Punto de Inicio	Punto Final	# Individuos	# Generaciones	Probabilidad de Cruza	Probabilidad de Mutación	# Generaciones
4.1	[1,1]	[8,8]	50	40	0.9	0.3	50
4.2	[1,1]	[8,8]	60	80	0.9	0.4	100
4.3	[4,4]	[1,8]	40	40	0.9	0.4	50
4.4	[4,4]	[1,8]	60	80	0.9	0.4	100

Cuadro 1: Parámetros del AG de cada escenario propuesto

4.1. Escenario esquina a esquina sin obstáculos

Es necesario de 50 generaciones para que el algoritmo converja con mayor probabilidad al punto final considerando parámetros descritos anteriormente (Ver Figuras 3 y 4).

4.2. Escenario esquina a esquina con obstáculos

En este escenario, se tuvo que aumentar el tamaño de la población, el tamaño de cada individuo y la probabilidad de mutación, esto para aumentar la diversidad de la población y la probabilidad de converger; así mismo, el número de generaciones para obtener soluciones con menor costo. Todo esto porque la complejidad del mapa aumenta (Ver Figuras 5 y 6).

4.3. Escenario centro a esquina sin obstáculos

Al igual que en el escenario 3.1, con 50 generaciones, se obtuvieron buenos resultados para este caso, el algoritmo llega al punto final con casi las mismas condiciones, pero aquí

se aumentó la probabilidad de mutación para tener mayor exploración del mapa, ya que es más fácil de tener una mala convergencia (Ver Figuras 7 y 8).

4.4. Escenario centro a esquina con obstáculos

A pesar de tener que recorrer menos casillas a la meta, se consideraron parámetros parecidos al del 3.2 porque al tener obstáculos y estar en el centro, es mucho más fácil una mala convergencia que en el 3.3 (Ver Figuras 9 y 10).




Figura 3: Interfaz gráfica escenario 4.1




Figura 5: Interfaz gráfica escenario: 4.2




Figura 4: Costos de mejor individuo por generación, escenario 4.1




Figura 6: Costos de mejor individuo por generación, escenario: 4.2




Figura 7: Interfaz gráfica escenario: 4.3




Figura 9: Interfaz gráfica escenario: 4.4

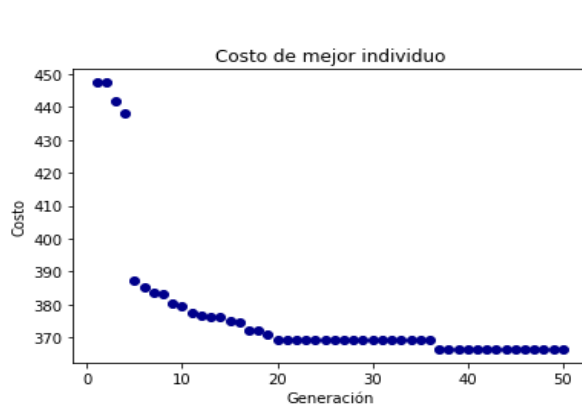


Figura 8: Costos de mejor individuo por generación, escenario: 4.3




Figura 10: Costos de mejor individuo por generación, escenario: 4.4

5. Conclusiones y trabajo futuro

Se desarrolló una interfaz gráfica que funciona con el AG también desarrollado por el equipo, donde personas encargadas de logística, que mayormente son ingenieros industriales, primero configuran el ambiente para luego obtener una ruta cercana a la óptima del punto de inicio al punto final. A pesar de que muchas veces no se obtiene la ruta óptima, siempre se logra a través de la configuración de los parámetros del AG una ruta posible, lo cual confirma la utilidad de este tipo de algoritmos, además los resultados obtenidos son muy útiles para la navegación de robots móviles.

Los mejores parámetros del AG en cuestión son los que se toman en cuenta para los escenarios 3.2 y 3.4, ya que resuelven el mayor número de casos por que hay mayor diversidad de población, mayor probabilidad de llegar al objetivo y mayor exploración del mapa (Ver escenarios 4.2 y 4.4).

Para un futuro trabajo se espera desarrollar un método para obtener mejores rutas y más rápido, comparado con el del presente trabajo; así como mejorar la interfaz de usuario para tener mayor control sobre las variables del algoritmo, ya que los entornos donde ingenieros industriales trabajan nunca son los mismos.

- [1] Zhang, X., Zhao, Y., Deng, N., and Guo, K. (2016). Dynamic path planning algorithm for a mobile robot based on visible space and an improved genetic algorithm. *International Journal of Advanced Robotic Systems*, 13(3), 91.
- [2] Tibaduiza A., (2006). Planeamiento de trayectorias de un robot móvil (Tesis de maestría). Universidad Industrial de Santander, Bucaramanga.
- [3] Gonzáles H., y Mejía C., (2007). Estudio comparativo de tres técnicas de navegación para robots móviles. *UIS Ingenierías*, 6(1), 78-84.
- [4] Méndez G. (2000). Diseño de un algoritmo genético para un sistema logístico de distribución. *Ciencia, investigación y desarrollo*, 5(1), 20-27.
- [5] Goldberg, D. E. (1989). *Genetic algorithms in search, optimization, and machine learning*, addison-wesley, reading, ma, 1989. NN Schraudolph and J, 3(1).
- [6] Ruge, I. A., y Alvis, M. A. (2009). Aplicación de los algoritmos genéticos para el diseño de un controlador PID adaptativo. *Tecnura*, 13(25), 81-87.
- [7] Syarif, A., Yun, Y., y Gen, M. (2002). Study on multi-stage logistic chain network: a spanning tree-based genetic algorithm approach. *Computers and Industrial Engineering*, 43(1-2), 299-314.

- [8] Ho, W., Ho, G. T., Ji, P., y Lau, H. C. (2008). A hybrid genetic algorithm for the multi-depot vehicle routing problem. *Engineering Applications of Artificial Intelligence*, 21(4), 548-557.
- [9] Owusu-Heneng, A. (2015). A genetic algorithm model for vehicle routing problem (VRP) (Doctoral dissertation). A Genetic Algorithm Method for Vehicle Routing Problem (VRP) (pp. 107 - 122).
- [10] Rathore, N., Jain, P. K., and Parida, M. (2020). A MATLAB-Based Application to Solve Vehicle Routing Problem Using GA. In *Advances in Simulation, Product Design and Development* (pp. 285-298). Springer, Singapore.
- [11] Tu, J.,; Yang, S. X. (2003, September). Genetic algorithm based path planning for a mobile robot. In *2003 IEEE International Conference on Robotics and Automation* (Cat. No. 03CH37422) (Vol. 1, pp. 1221-1226). IEEE.
- [12] Deng, Y., Liu, Y.,; Zhou, D. (2015). An improved genetic algorithm with initial population strategy for symmetric TSP. *Mathematical Problems in Engineering*, 2015.
- [13] Meneses, A., Rodríguez, K., Torres, C. and Castro, K.. (2005). *Introducción a los Algoritmos Genéticos. Implementación en C++, Java y MATLAB*. CDMX.: Grupo de Computación Bioinspirada DISCA-IIMAS-UNAM.
- [14] Zhang, A., Li, C., and Bi, W. (2016). Rectangle expansion A pathfinding for grid maps. *Chinese Journal of Aeronautics*, 29(5), 1385-1396.
- [15] Sturtevant, N. R. (2012). Benchmarks for grid-based pathfinding. *IEEE Transactions on Computational Intelligence and AI in Games*, 4(2), 144-148.
- [16] Márquez, J. E. (2012). Algoritmo genético aplicado a la programación en talleres de maquinado. *Scielo*, 15(3).
- [17] Veslin, E. (2014). Aplicación de algoritmos genéticos en problemas de Ingeniería. *Facultad de Ciencias e Ingeniería* (1).
- [18] Huguet, J. Mejora del sistema de gestión del almacén de suministros de una empresa productora de gases de uso medicinal e industrial. *Actualidad y Nuevas Tendencias*, 17(5).
- [19] Correa, A. (2009). *Tecnologías de la información y comunicación de la gestión de almacenes*. Universidad Nacional de Colombia. 26(117), 145-171.
- [20] Sierra, D. y Martínez, R. (2002). Planeación de trayectorias para un robot en una celda de manufacturas 2(1).
- [21] Medina, J. y Yepes, V. (2000). Optimización de redes de distribución con algoritmos genéticos.
- [22] Martínez, Barrero y Tibaduiza, D. (2006). Algoritmos de planificación de trayectorias para un robot móvil.

- [23] Becerril I. y Villa G. (2013). Diseño de un algoritmo genético para resolver problemas de ruteo de vehículo.
- [24] Guzmán M. y Peña C. (2013). Algoritmos bioinspirados en la planeación off-line de trayectorias de robots seriales. 7(1), 27-39.
- [25] Jiménez M., (2018). Algoritmo Genético Simple para Resolver el Problema de Programación de la Tienda de Trabajo.29(5).